


Conectividade

Francisco Rodrigues

Instituto de Ciências Matemáticas e de Computação

Universidade de São Paulo

<https://sites.icmc.usp.br/francisco>



Internet graph
(by the Opte Project)

Grau de um vértice


- Considere um grafo simples e não dirigido com N vértices.
- Sua matriz de adjacência A é definida por:

$$A_{ij} = \begin{cases} 1, & \text{se os vértices } i \text{ e } j \text{ estão conectados,} \\ 0, & \text{caso contrário.} \end{cases}$$

- Para um grafo não dirigido: $A_{ij} = A_{ji}$.
- O grau do vértice i é:

$$k_i = \sum_{j=1}^N A_{ij}$$


- Portanto, k_i conta quantos vizinhos o vértice i possui.



$$A = \begin{matrix} & \begin{matrix} 1 & 2 & 3 & 4 \end{matrix} \\ \begin{matrix} 1 \\ 2 \\ 3 \\ 4 \end{matrix} & \begin{bmatrix} 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 1 \\ 1 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix} \end{matrix}$$


Grau médio

$$\langle k \rangle = \frac{1}{N} \sum_{i=1}^N k_i$$



$$\langle k \rangle = \frac{1}{7} \sum_{i=1}^7 k_i = \frac{2 + 2 + 6 + 2 + 2 + 2 + 3}{7} = \frac{19}{7} = 2.71$$

Redes dirigidas



$$\langle k^{\text{in}} \rangle = \frac{1}{N} \sum_{i=1}^N k_i^{\text{in}},$$


$$\langle k^{\text{in}} \rangle = \frac{1+1+1+0+2}{5} = 1,$$

$$\langle k^{\text{out}} \rangle = \frac{1}{N} \sum_{i=1}^N k_i^{\text{out}},$$


$$\langle k^{\text{out}} \rangle = \frac{2+0+1+2+0}{5} = 1.$$

Distribuição de grau


a.




b.



c.





d.





Distribuição de grau

$$P(k) = \frac{N_k}{N} \quad k = 0, 1, \dots, k_{max}$$







Distribuição de grau

$$P(k) = \frac{e^{-\langle k \rangle} \langle k \rangle^k}{k!}.$$




$$P(k) \approx k^{-\gamma},$$




Lei de potência


a. POISSON



b.




c. POWER LAW






d.









Lei de potência



$$P(k) \approx k^{-\gamma}$$




Distribuição de grau




$$P(k) \approx k^{-\gamma},$$


$$\log(P(k)) = C - \gamma \log(k),$$



(a) Collaboration in astrophysics



(b) Protein interaction network



(c) Internet network

Lei de potência: universalidade na natureza

Como uma lei simples explica os mais diversos fenômenos na natureza, desde as redes sociais até os terremotos.



Francisco Rodrigues, PhD  14 min read · Apr 16, 2023



69



2



Galileo Galilei não teve uma vida fácil. Na velhice, foi condenado à prisão domiciliar por afirmar que a Terra girava em torno do Sol. Na juventude, em 1580, teve que se matricular, a contragosto, em medicina na Universidade de Pisa. Seu pai queria que ele fosse médico, pois não via futuro em um filho matemático. Galileo não parece ter dado muita importância aos estudos de medicina, optando por frequentar cursos sobre seus reais interesses, que eram matemática e filosofia natural. Como resultado, ele deixou Pisa em

<https://medium.com/@francisco-rodrigues/lei-de-pot%C3%Aancia-universalidade-na-natureza-eb016dcaf74e>


- Média
- Mediana
- Variância
- Desvio padrão
- Quantil
- Percentil
- Boxplot
- ...

$$\text{Mediana}(X) = \begin{cases} 1/2(X_r + X_{r+1}), & \text{se } n \text{ for par } (n = 2r) \\ X_{r+1}, & \text{se } n \text{ for ímpar } (n = 2r + 1), \end{cases}$$

- Exemplos:
 - {17, 4, 8, 21, 4}
 - Ordenando: 4, 4, 8, 17, 21
 - Número ímpar de elementos $\Rightarrow$ mediana = 8
 - {17, 4, 8, 21, 4, 15, 13, 9}
 - Ordenando: 4, 4, 8, 9, 13, 15, 17, 21
 - Número par de elementos $\Rightarrow$ mediana = $(9+13)/2 = 11$


Média X Mediana

Distribuição Normal



(a)

Distribuição Exponencial



(b)

Média —
Mediana - -

Média e Mediana

Python

```
import numpy as np
X = [1,1,1,2,2,3,4,5,5,5]
mx = np.mean(X)
print('X:', X)
print('A média:', mx)
```

X: [1, 1, 1, 2, 2, 3, 4, 5, 5, 5]
A média: 2.9

```
md = np.median(X)
print('X:', X)
print('A mediana:', md)
```

X: [1, 1, 1, 2, 2, 3, 4, 5, 5, 5]
A mediana: 2.5

```
X2 = [1,1,1,2,2,3,4,5,5,100]
print('X2:', X2)
print('A nova média:', np.mean(X2))
print('A nova mediana:', np.median(X2))
```

X2: [1, 1, 1, 2, 2, 3, 4, 5, 5, 100]
A nova média: 12.4
A nova mediana: 2.5

Quartil e percentil

Quartis


- Divide em quartos
 - 1º quartil (Q_1) $\Rightarrow$ valor que tem 25% dos demais valores abaixo dele
 - 2º quartil (Q_2) = mediana
 - 3º quartil (Q_3) $\Rightarrow$ valor que tem 75% dos demais valores abaixo dele

Percentil

- Para p entre 0 e 100
- p percentil = $P_p \Rightarrow x_i$ tal que $p\%$ dos valores observados são menores do que x_i
- $P_{25} = Q_1$
- $P_{50} = Q_2 = \text{mediana}$



Quartil e percentil

$$X = \{9, 3, 11, 14, 20, 4, 6, 17, 30, 21, 23, 16\}$$



$$Q1 = 7,5, Q2 = 15 \text{ e } Q3 = 20,5$$

Boxplots



Medidas de dispersão

- Dois conjuntos de dados podem apresentar as mesmas medidas de posição.
- Por exemplo, os conjuntos $X = \{0,0,1,1,18\}$ e $Y = \{4,4,4,4,4\}$ possuem a mesma média igual a 4.
- Ou seja, se usarmos apenas a média para caracterizar os dados, vamos concluir que ambos são iguais.
- Medem **dispersão** ou **espalhamento** de um conjunto de valores
 - Permitem observar se valores estão:
 - Espalhados
 - Concentrados em torno de um valor (ex. da média)
 - Medidas mais comuns:
 - Variância
 - Desvio padrão
 - IQR

Medidas de dispersão

- **Variância**

$$\sigma^2 = E[(X - E(X))^2] = E[X^2] - E[X]^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2$$

- **Desvio padrão:**

- População

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2}$$

- Amostra

$$\sigma = \sqrt{\frac{1}{N-1} \sum_{i=1}^N (x_i - \mu)^2}$$

Estimador não-viesado.

Medidas de dispersão

- Exemplo: Sejam os vetores: $X = \{0, 0, 1, 1, 18\}$ e $Y = \{4, 4, 4, 4, 4\}$.

$$\mu = \frac{\sum_{i=1}^N x_i}{N} = 4$$

$$\sigma^2 = E[(X - E(X))^2] = E[X^2] - E[X]^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2$$

$$\sigma_X^2 = \frac{(0-4)^2 + (0-4)^2 + (1-4)^2 + (1-4)^2 + (18-4)^2}{5-1} = 61,5$$

$$\sigma_Y^2 = \frac{(4-4)^2 + (4-4)^2 + (4-4)^2 + (4-4)^2 + (4-4)^2}{5-1} = 0$$

Medidas de dispersão

- Outras medidas de dispersão:

- Distância interquantil:

- $IQR = Q_3 - Q_1$

- Amplitude:



- $R(X) = \max(X) - \min(X)$

Ex:

$$X = \{9, 3, 11, 14, 20, 4, 6, 17, 30, 21, 23, 16\}$$

$$IQR = Q_3 - Q_1 = 20,5 - 7,5 = 13$$

$$R(X) = 30 - 3 = 27$$



```
from scipy.stats import iqr

def variancia(X):
    m = np.mean(X)
    N = len(X)
    s = 0
    for i in np.arange(0, len(X)):
        s = s + (X[i]-m)**2
    s = s/(N-1)
    return s

X = [0,0,1,1,18]
Y = [4, 4, 4, 4, 4]
mx = np.mean(X)
my = np.mean(Y)
print('X:', X)
print('Média de X:', mx)
print('Variância de X:', variancia(X))
print('IQR de X:', iqr(X))
print('Amplitude de X:', np.max(X)-np.min(X))

print('\n')
print('Y:', Y)
print('Média de Y:', my)
print('Variância de Y:', variancia(Y))
print('IQR de Y:', iqr(Y))
print('Amplitude de Y:', np.max(Y)-np.min(Y))
```

X: [0, 0, 1, 1, 18]
Média de X: 4.0
Variância de X: 61.5
IQR de X: 1.0
Amplitude de X: 18

Y: [4, 4, 4, 4, 4]
Média de Y: 4.0
Variância de Y: 0.0
IQR de Y: 0.0
Amplitude de Y: 0

Notem que os dados acima possuem a mesma média, mas a variância é bastante diferente.

Coeficiente de variação

- É uma medida de dispersão relativa, expressando a variabilidade em relação à média.

$$CV = \frac{\sigma_X}{\bar{X}} \times 100, \quad \bar{X} \neq 0$$

	Média	Desvio Padrão	CV
Altura	1,143 m	0,063 m	5,5%
Peso	50 Kg	6 Kg	12%

- Conclusão: O peso dos alunos apresenta variabilidade relativa duas vezes maior do que a altura.

Centralidade de grau

- Em alguns contextos, principalmente em análise de redes sociais, utiliza-se a **centralidade de grau normalizada**:

$$C_D(i) = \frac{k_i}{N - 1}.$$

- O denominador $N-1$ corresponde ao maior grau possível para um vértice em uma rede simples não dirigida.

$$0 \leq C_D(i) \leq 1$$

Momentos da distribuição de graus

- Uma distribuição completa contém muita informação.
- Em várias aplicações, queremos resumi-la por alguns números.
- O **momento de ordem m** é dado por:



$$\langle k^m \rangle = \sum_k k^m P(k) = \frac{1}{N} \sum_{i=1}^N k_i^m$$

- Para $m=1$, temos o grau medio:

$$\langle k \rangle = \sum_k k P(k) = \frac{1}{N} \sum_{i=1}^N k_i$$

Momentos da distribuição de graus



$$\langle k^2 \rangle = 0^2 \times 0 + 1^2 \times \frac{3}{8} + 2^2 \times \frac{4}{8} + 3^2 \times \frac{1}{8} = \frac{7}{2} = 3.5.$$



$$\langle k^2 \rangle = 0^2 \times \frac{1}{8} + 1^2 \times \frac{3}{8} + 2^2 \times \frac{1}{8} + 3^2 \times \frac{3}{8} = \frac{17}{4} = 4.25,$$

Medidas estatísticas

- **Variância:** $\text{Var}(k) = \langle k^2 \rangle - \langle k \rangle^2$
- **Desvio padrão:** $\sigma = \sqrt{\langle k^2 \rangle - \langle k \rangle^2}$
- **Índice de heterogeneidade:** $H_k = \frac{\langle k^2 \rangle}{\langle k \rangle^2}$
- **Assimetria:** $\text{Skew}(k) = \frac{\langle (k - \langle k \rangle)^3 \rangle}{\sigma_k^3}$
- **Curtose:** $\text{Kurt}(k) = \frac{\langle (k - \langle k \rangle)^4 \rangle}{\sigma_k^4}$



- **Entropia da distribuição de graus:**

$$S_k = - \sum_{k:P(k)>0} P(k) \ln P(k)$$

- **Número efetivo de graus:**

$$D_k = e^{S_k}$$

Essa quantidade pode ser entendida como um número efetivo de classes de grau. Se existem m graus diferentes com probabilidades exatamente iguais, então $S_k = \ln m$.

Coeficiente de Gini

- O **coeficiente de Gini** pode ser definido por

$$G_k = \frac{\sum_{i=1}^N \sum_{j=1}^N |k_i - k_j|}{2N \sum_{i=1}^N k_i}$$

- Para uma rede não vazia, $G_k = 0$ quando todos os graus são iguais.
- Valores maiores indicam maior desigualdade com relação ao grau.

Grau médio dos vizinhos

- **Grau médio dos vizinhos**
- Para um vértice i com $k_i > 0$, definimos

$$k_{nn,i} = \frac{1}{k_i} \sum_j A_{ij} k_j$$


- Podemos agrupar vértices com o mesmo grau e definir

$$k_{nn}(k) = \frac{1}{N_k} \sum_{i:k_i=k} k_{nn,i}$$

- Usando a distribuição condicional,

$$k_{nn}(k) = \sum_{k'} k' P(k' | k)$$

Grau médio dos vizinhos




$$k_{nn,i} = \frac{1}{k_i} \sum_j A_{ij} k_j$$

$$\overline{k_{nn}}(v) = \frac{1}{k(v)} \sum_{i=1}^{k(v)} k(u_i) = \frac{6 + 4 + 2 + 4}{4} = 4$$

Grau médio dos vizinhos

$$k_{nn}(k) = \frac{1}{N_k} \sum_{i:k_i=k} k_{nn,i}$$

- se $k_{nn}(k)$ cresce com k , temos uma tendência **assortativa**;
- se $k_{nn}(k)$ decresce com k , temos uma tendência **disassortativa**;
- se $k_{nn}(k)$ é aproximadamente constante, a rede pode ser aproximadamente não correlacionada em termos de grau.



- Assortatividade de grau

$$r = \frac{\frac{1}{M} \sum_{(i,j) \in E} k_i k_j - \left[\frac{1}{M} \sum_{(i,j) \in E} \frac{k_i + k_j}{2} \right]^2}{\frac{1}{M} \sum_{(i,j) \in E} \frac{k_i^2 + k_j^2}{2} - \left[\frac{1}{M} \sum_{(i,j) \in E} \frac{k_i + k_j}{2} \right]^2}, \quad -1 \leq r \leq 1.,$$

$r > 0$: rede assortativa;

$r < 0$: rede disassortativa;

$r \approx 0$: ausência de correlação linear significativa entre graus nas extremidades das arestas.

Centralização de grau

- **Centralização de grau:**

- A centralidade de grau é uma propriedade de um vértice.
- Proposta por Freeman (1978), é uma propriedade da rede inteira

$$C_D = \frac{\sum_{i=1}^N (k_{\max} - k_i)}{(N-1)(N-2)}$$

- O denominador corresponde ao valor máximo possível do numerador, atingido por uma estrela.
- Essa medida é diferente do Gini. O Gini resume desigualdade entre todos os graus. A centralização de Freeman compara todos os vértices especificamente com o vértice de grau máximo.



- **Índice h dos graus**

- O índice h é usado para medir produtividade científica.
- O índice h é o maior número tal que existam pelo menos h nós com grau $\geq h$.
- Formalmente, ordenando os graus em ordem decrescente

$$k_{(1)} \geq k_{(2)} \geq \dots \geq k_{(N)}:$$

$$h = \max\{ i : k_{(i)} \geq i \}$$

- O índice h combina, em um único número, informação sobre quantidade de nós bem conectados e magnitude dos seus graus.
- É mais robusto a outliers extremos do que k_{max} isoladamente.



<https://networksciencebook.com/>

Advances in Physics,
Vol. 56, No. 1, February 2007, 167–242



Characterization of complex networks: A survey of measurements

L. DA F. COSTA*, F. A. RODRIGUES,
G. TRAVIESO and P. R. VILLAS BOAS

Instituto de Física de São Carlos, Universidade de São Paulo,
Caixa Postal 369, 13560-970, São Carlos, SP, Brazil

(Received 21 August 2006; in final form 4 December 2006)

Each complex network (or class of networks) presents specific topological features which characterize its connectivity and highly influence the dynamics of processes executed on the network. The analysis, discrimination, and synthesis of complex networks therefore rely on the use of measurements capable of expressing the most relevant topological features. This article presents a survey of such measurements. It includes general considerations about complex network characterization, a brief review of the principal models, and the presentation of the main existing measurements. Important related issues covered in this work comprise the representation of the evolution of complex networks in terms of trajectories in several measurement spaces, the analysis of the correlations between some of the most traditional measurements, perturbation analysis, as well as the use of multivariate statistics for feature selection and network classification. Depending on the network and the analysis task one has in mind, a specific set of features may be chosen. It is hoped that the present survey will help the proper application and interpretation of measurements.