

Avaliação

Francisco Rodrigues

Instituto de Ciências Matemáticas e de Computação

Universidade de São Paulo

francisco@icmc.usp.br

Avaliação

- Problema de duas classes:
 - Tipos de erros:



Avaliação

- Problema de duas classes:
- Medidas de desempenho:

		Classe Predita	
		Positivo	Negativo
Classe Verdadeira	Positivo	Verdadeiro Positivo (VP)	Falso Negativo (FN)
	Negativo	Falso Positivo (FP)	Verdadeiro Negativo (VN)

Sensibilidade: $VP / (VP + FN)$

Precisão: $VP / (VP + FP)$

Especificidade: $VN / (VN + FP)$

Avaliação

- **Problema de duas classes:**
 - Medidas de desempenho:

- **Erro total:**

$$E(f) = \frac{FP + FN}{n}$$


- **Acurácia total:**

$$Ac(f) = \frac{VP + VN}{n}$$

Verdadeiro Positivo (VP)	Falso Negativo (FN)
Falso Positivo (FP)	Verdadeiro Negativo (VN)


Avaliação

- Problema de duas classes:
- **Falso positivo:** o modelo prevê que o caso é positivo, mas na realidade ele é negativo. Por exemplo, classificar uma pessoa saudável como doente.
- **Falso negativo:** o modelo prevê que o caso é negativo, mas na realidade ele é positivo. Por exemplo, classificar uma pessoa doente como saudável.



Avaliação

- Problema de duas classes:
- **Verdadeiro positivo:** o modelo prevê que o caso é positivo e ele realmente é positivo. Por exemplo, classificar corretamente uma pessoa doente como doente.
- **Verdadeiro negativo:** o modelo prevê que o caso é negativo e ele realmente é negativo. Por exemplo, classificar corretamente uma pessoa saudável como saudável.



Avaliação

- **Problema de duas classes:**

- Medidas de desempenho:


Verdadeiro Positivo (VP)	Falso Negativo (FN)
Falso Positivo (FP)	Verdadeiro Negativo (VN)

- **Precisão (precision):** avalia a quantidade de verdadeiros positivos sobre a soma de todos os valores positivos:

$$\text{Prec}(f) = \frac{VP}{VP + FP}$$

- **Sensibilidade (recall):** avalia a capacidade do método de detectar resultados positivos. Útil quando o custo de falsos negativos é alto.

$$S(f) = \frac{VP}{VP + FN}$$




Avaliação

- Problema de duas classes:
- Medidas de desempenho:
 - **Especificidade (true negative rate):** avalia a capacidade do método de detectar resultados negativos.
- **Medida F1:** Média harmônica da precision e recall.


Verdadeiro Positivo (VP)	Falso Negativo (FN)
Falso Positivo (FP)	Verdadeiro Negativo (VN)

$$\text{Esp}(f) = \frac{VN}{VN + FP}$$

$$F1(f) = \frac{2S(f)\text{Prec}(f)}{S(f) + \text{Prec}(f)}$$



Avaliação



$$\text{Precision} = \frac{5 \text{ true pos.}}{8 \text{ total pos.}} \quad \bigg| \quad \text{Recall} = \frac{5 \text{ true pos.}}{12 \text{ total dogs}}$$


$$\text{Prevalence} = \frac{12 \text{ total dogs}}{22 \text{ total images}}$$

$$\text{Accuracy} = \frac{5 \text{ true pos.} + 7 \text{ true neg.}}{22 \text{ total images}}$$


Avaliação

- Medida F1:
- Desvantagens:
 - Não considera os verdadeiros negativos, que podem ser necessário em alguns cenários.
 - Ele assume a mesma importância da precision e da recall.
 - Não possui simetria. Seu valor pode mudar se rotularmos novamente amostras "positivas" como "negativas" e vice-versa.


Verdadeiro Positivo (VP)	Falso Negativo (FN)
Falso Positivo (FP)	Verdadeiro Negativo (VN)



Precisão (Precision)
Dos itens recuperados, quantos são relevantes?



Revocação (Recall)
Dos itens relevantes, quantos foram recuperados?



$$F_1 = \frac{1}{Pr^{-1} + Re^{-1}} = \frac{2 \cdot TP}{2 \cdot TP + FP + FN}$$

True Positive (TP), False Positive (FP), False Negative (FN), Precision (Pr), Recall (Re)

Avaliação

- Problema de duas classes:

- Exemplo:

- **Acurácia:** $Ac(f) = \frac{VP + VN}{n} = \frac{70 + 60}{200} = 0.65$

- Precision (precisão):

$$Prec(f) = \frac{VP}{VP + FP} = \frac{70}{70 + 40} = 0.64$$

- Sensibilidade (recall):

$$S(f) = \frac{VP}{VP + FN} = \frac{70}{70 + 30} = 0.7$$


- Especificidade (true negative rate): $Esp(f) = \frac{VN}{VN + FP} = \frac{60}{60 + 40} = 0.60$

		Predito	
		p	n
Verdadeiro	p	VP	FN
	n	FP	VN

		p		n	
		p		n	
Verdadeiro	p	70	30		
	n	40	60		

Curva ROC (Receiver Operating Characteristic)

A curva ROC mostra o desempenho de um classificador para todos os possíveis limiares de decisão.



💡 Quanto maior a área sob a curva (AUC), melhor o desempenho do classificador. A curva ROC é independente do limiar e do desbalanceamento das classes.

1. Eixos

- **Eixo x (FPR):** proporção de negativos classificados incorretamente como positivos (falsos positivos).
- **Eixo y (TPR):** proporção de positivos classificados corretamente (verdadeiros positivos).

2. Pontos da curva

Cada ponto representa o desempenho do classificador para um limiar específico. Ao variar o limiar de decisão de 1 $\rightarrow$ 0, obtemos diferentes combinações de TPR e FPR.

3. Canto superior esquerdo

Região desejável: alta sensibilidade (TPR próxima de 1) e baixa taxa de falsos positivos (FPR próxima de 0).


4. Linha tracejada (diagonal)

Representa um classificador aleatório, com desempenho equivalente a chutar. $AUC = 0.5$.

5. AUC (Área sob a curva)


- Mede o desempenho global do classificador:
- $AUC = 1.0 \rightarrow$ classificador perfeito
 - $AUC = 0.5 \rightarrow$ desempenho aleatório
 - $AUC < 0.5 \rightarrow$ pior que aleatório

		Detectada	
		Sim	Não
Real	Sim	Verdadeiro Positivo (VP)	Falso Negativo (FN)
	Não	Falso Positivo (FP)	Verdadeiro Negativo (VN)





Avaliação

- Problema de duas classes:
 - Curva ROC (Receiving Operating Characteristics):



Avaliação



- Problema de duas classes:
 - Curva ROC (Receiving Operating Characteristics):



TP	FP
FN	TN



Avaliação

- Problema de duas classes:
 - Curva ROC (Receiving Operating Characteristics):





Avaliação

- Problema de duas classes:
- Curva ROC (Receiving Operating Characteristics):




Avaliação

- Problema de duas classes:
- Curva ROC (Receiving Operating Characteristics):
 - Área sob a curva ROC:
 - Produz valores no intervalo $[0,1]$
 - Valores mais próximos de 1 são considerados melhores.



Avaliação




- **Propriedades da Curva ROC:**
- Permite realizar medidas de desempenho independentes do limiar de classificação e de custos associados às classificações incorretas e distribuição das classes.
 - Uso de diferentes limiares representa maior ou menor ênfase à classe positiva.
 - Taxa de erro/acerto é bastante sensível a desbalanceamentos (ex. conjunto com 90 + e 10 -, taxa de acerto de 0,90 não necessariamente indica bom desempenho preditivo)
- **Desvantagem:** análise originalmente limitada a classificação binária.

$$\text{Prec}(f) = \frac{VP}{VP + FP} \quad S(f) = \frac{VP}{VP + FN}$$

- **Precision-Recall**

- Um gráfico ou curva de Precision-Recall é uma ferramenta de avaliação de modelos que plota a precisão no eixo vertical (Y) em função do recall no eixo horizontal (X).
- A curva Precision-Recall não substitui necessariamente a ROC, mas fornece uma visão complementar, especialmente quando o interesse principal está na qualidade das predições positivas.



$$\text{Prec}(f) = \frac{VP}{VP + FP} \quad S(f) = \frac{VP}{VP + FN}$$

- **Precision-Recall**

- **É mais adequada para dados desbalanceados:** Quando a classe positiva é rara, como em diagnósticos médicos, detecção de fraudes ou identificação de transtornos, a curva ROC pode dar uma impressão excessivamente otimista. A curva Precision-Recall mostra melhor o desempenho do modelo na classe que realmente interessa.
- **Foca diretamente na classe positiva:** Ela avalia a capacidade do modelo de encontrar corretamente os casos positivos e, ao mesmo tempo, verificar se as predições positivas são confiáveis.
- **Mostra o compromisso entre precisão e revocação:** A curva permite observar a troca entre encontrar mais casos positivos e evitar falsos positivos. Em geral, ao aumentar o recall, a precisão pode diminuir.
- **Ajuda na escolha do limiar de decisão:** A curva permite escolher um ponto de operação adequado para o modelo, dependendo do objetivo do problema: maior precisão, maior recall ou um equilíbrio entre os dois.
- **É útil quando falsos positivos têm custo alto:** Em algumas aplicações, classificar incorretamente um caso negativo como positivo pode gerar custos financeiros, clínicos ou operacionais. A curva ajuda a avaliar esse tipo de erro.